

アルゴリズムとデータ構造⑤

～ 順序統計量・動的計画法 ～

鹿島久嗣

順序統計量

順序統計量：

小さい方から k 番目の要素は線形時間で発見可能

- 順序統計量：小さい方から k 番目の要素
 - 自明なやり方：ソートを使えば $O(n \log n)$
 - 工夫すれば $O(n)$ で可能：
 - 平均的に $O(n)$ で見つける方法（前回）
 - **最悪ケースで $O(n)$ で見つける方法（今回）**
- の二つのやり方を紹介する

平均 $O(n)$ の順序統計量アルゴリズム：

クイックソートと同じ考え方で可能だが、最悪ケースで $O(n^2)$

- $q \leftarrow \text{Partition}(A, p, r)$ の結果：

配列 $A[p, r]$ を枢軸以下の要素と
大きい要素に分け q の前後に分割

1. $k \leq q$ であれば、求める要素は $A[p:q]$ にある

2. $k > q$ であれば、求める要素は $A[q + 1:r]$ にある

—再帰的にPartitionを呼ぶことで範囲を限定していく

- 平均的には問題サイズは半々になっていくので $O(n)$

$$T(n) = T\left(\frac{n}{2}\right) + O(n) = O(n)$$

- 最悪ケースでは問題サイズは定数しか減らないので $O(n^2)$

- 問題サイズが確実に比率で減っていくようにしたい

最悪 $O(n)$ の順序統計量アルゴリズム： うまく「だいたい真ん中」をとってくる

- $\text{Order}(A, k)$: A の中から k 番目に小さい要素を見つける
 1. A を5個ずつのグループに分け、各グループをソートして中央値（3番目の値）を見つけ、これらを集めて T とする（定数個の要素のソートは定数時間でできることに注意）
 2. T の中央値 m をみつける $\text{Order}(T, \lfloor n/10 \rfloor)$
 3. A を m より小さいもの（ S_1 ）、同じもの（ S_2 ）、大きいもの（ S_3 ）に分割する
 4. (i) $k \leq |S_1|$ ならば $\text{Order}(S_1, k)$ を実行
(ii) $|S_1| < k \leq |S_1| + |S_2|$ ならば m は目的の要素
(iii) $k > |S_1| + |S_2|$ ならば
 $\text{Order}(S_3, k - (|S_1| + |S_2|))$ を実行する。

最悪 $O(n)$ の順序統計量アルゴリズム： うまく「だいたい真ん中」をとってくる

■ $\text{Order}(A, k)$: A の中から k 番目に小さい要素を見つける

1. A を5個ずつのグループに分け、各グループをソートして中央値（3番目の値）を見つけ、これらを集めて T とする（定数個の要素のソートは定数時間でできることに注意）

2. T の中央値 m を見つける $\text{Order}(T, \lfloor n/10 \rfloor)$


3. A を m より小さいもの（ S_1 ）、中央値（ S_2 ）、大きいもの（ S_3 ）に分ける

4. (i) $k \leq |S_1|$ のとき

(ii) $|S_1| < k$ のとき

(iii) $k > |S_1|$ のとき

$\text{Order}(S_1, k)$



目的の要素

する。

最悪 $O(n)$ の順序統計量アルゴリズム： 計算量の漸化式

- $T(n) = O(n) + T\left(\left\lfloor \frac{n}{5} \right\rfloor\right) + T\left(\left\lceil \frac{3}{4}n \right\rceil\right) = O(n)$
 - ステップ4の分岐で (i) $\text{Order}(S_1, k)$ が選ばれたとする
 - 中央値 m 以上の要素が少なくとも $\frac{1}{4}n$ 個ある
 - したがって中央値より小さい要素数は最大 $\frac{3}{4}n$ 個
- 直観的には「各グループの中央値を集めた中の中央値は概ね全体の中央値になっている」
 - 全体を分割した小グループのそれぞれの中央値をあつめてその中央値をとると、おおむね全体の中央値が取れるはず

最悪 $O(n)$ の順序統計量アルゴリズム： 計算量の漸化式

- $T(n) = O(n) + T\left(\left\lfloor \frac{n}{5} \right\rfloor\right) + T\left(\left\lceil \frac{3}{4}n \right\rceil\right) = O(n)$


- ステップ4の分岐で (i) $\text{Order}(S_1, k)$ が選ばれたとする

- 中央値 m 以上の要素が少なくとも $\frac{1}{4}n$ 個ある

したがって中央 → 大 $\frac{3}{4}n$ 個

■直観的には「各概ね全体の中

一 全体を分割し、その中央値を



最大 $\frac{3}{4}n$ 個
た中の中央値は

中央値をあつめて
中央値が取れるはず

最悪 $O(n)$ の順序統計量アルゴリズム： 計算量の導出

- 定理： $s_1 + s_2 + \cdots + s_d < 1$ として

$T(n)$

$$= \begin{cases} c & (n \leq n_0) \\ T(s_1 n) + T(s_2 n) + \cdots + T(s_d n) + c' n & (n > n_0) \end{cases}$$

とすると、 $T(n) \leq \frac{cn}{1-(s_1+s_2+\cdots+s_d)} = O(n)$

- 今回のケースでは $s_1 = \frac{1}{5}$, $s_2 = \frac{3}{4}$ であり、👉 の定理を使うと
 $T(n) = O(n)$

動的計画法

動的計画法：

問題を再帰的に分割しボトムアップに解く

- 動的計画法と分割統治法はともに問題を再帰的に分割

- 分割統治法：トップダウン

- 動的計画法：ボトムアップ

- 動的計画法の流れ

1. 問題の構造を再帰的に捉える

2. 解を再帰的に構成する

3. ボトムアップで解を計算する


} 分割統治法
と同じ

動的計画法のポイント： 解の使いまわしによる効率化

- 分割された問題が重複している場合に差が生じる
 - トップダウンでは同じ問題を何度も解くことになる
 - ボトムアップでは解の使いまわしが可能
 - 両者に指数的な差が生じる
- 逆にいえば、部分問題が重複していることが動的計画法のカギ

動的計画法のポイント： 解の使いまわしによる効率化


- 分割された問題が重複している場合に差が生じる



- 部分問題が重複していることが動的計画法のカギ

動的計画法の例： 複数の行列積の計算

- 入力： 行列 A_1, A_2, \dots, A_n
- 出力： 積 $A_1 A_2 \cdots A_n (= A_{1,\dots,n})$



- 掛け算できる前提
 - $A_i A_{i+1}$ の計算は $O(p_{i-1} p_i p_{i+1})$ にかかる
- $A_1: 10 \times 100, A_2: 100 \times 5, A_3: 5 \times 50$ とすると：
 - $(A_1 A_2) A_3 = 7500$
 - $A_1 (A_2 A_3) = 75000$

解の構成における観察：

全体の最適解は部分最適解の組合せで作られている

- $A_1 A_2 \cdots A_n (= A_{1,\dots,n})$ の計算において、 k 番目の分割が最後にくるとする
 - つまり $A_{1,\dots,k}$ と $A_{k+1,\dots,n}$ を別々に計算して最後に統合する
 - ちなみに、最後の統合コストは $O(p_0 p_k p_n)$
- これが最適解であるなら、 $A_{1,\dots,k}$ と $A_{k+1,\dots,n}$ の計算コストもそれぞれ最小のはず（部分問題の最適解のはず）
 - 理由：そうでなければ、それぞれをコスト最小のものに置き換えるだけで、全体のコストがもっと下がるはず
- つまり、全体最適解は、部分最適解でつくられている

最小コストについて成り立つ再帰式： 部分行列積の最適解を組合わせて大きな最適解をつくる

- $A_{i,\dots,j}$ を計算する最小のコストを $m[i, j]$ とする
- $m[i, j]$ は再帰的に表現できる：

$$m[i, j] = \begin{cases} 0 & (i = j) \\ \min_{i \leq k < j} m[i, k] + m[k + 1, j] + p_{i-1} p_k p_j & (i \neq j) \end{cases}$$

どこで分割するのが
最良か？

前半の最小
計算コスト

後半の最小
計算コスト

統合（掛け算）
のコスト

動的計画法の計算量：

ボトムアップ計算により多項式時間で解が求まる

- 再帰式の適用により最小の $m[1, n]$ を求める
- 「ボトムアップ」で計算：
 1. $i = j$ の場合について計算（全部ゼロ； $m[i, i] = 0$ ）
 2. $i = j - 1$ の場合について計算（ $m[i, i + 1]$ ）
 3. $i = j - 2$ の場合について計算（ $m[i, i + 2]$ ）
 4. ...

— 上記が n ステップ、それぞれで $O(n)$ 個の再帰式評価、それぞれの評価に $O(n)$ 必要なので、全部で $O(n^3)$ の計算量
- バックトラック：各再帰式での最良の k を記憶しておくことで実際の掛け算の順番を得る

動的計画法でやらないと... : 指数的な計算量になる

- 解きたい再帰式 :

$$m[i, j] = \begin{cases} 0 & (i = j) \\ \min_{i \leq k < j} m[i, k] + m[k + 1, j] + p_{i-1} p_k p_j & (i \neq j) \end{cases}$$

- トップダウン計算（分割統治）だと指数的な計算量になる

$$T(n) = \sum_{k=1}^{n-1} (T(k) + T(n-k) + c) = 2 \sum_{k=1}^{n-1} T(k) + cn = O(2^n)$$

最長共通部分系列問題：

2つの系列に共通に含まれる最長の部分系列を見つける

- 系列 $X = (x_1, x_2, \dots, x_m)$ の部分系列(subsequence)とは X からいくつかの要素を取り除いたもの
- 2つの系列 X と Y に対して、系列 Z が両方の部分系列のときこれを共通部分系列とよぶ
- 最長共通部分系列(LCS; Longest Common Sequence) :
 - 入力：2つの系列
$$X = (x_1, x_2, \dots, x_m), Y = (y_1, y_2, \dots, y_n)$$
 - 出力： X と Y のLCS $Z = (z_1, z_2, \dots, z_k)$ をひとつ

最長共通部分系列の性質： LCSも再帰的な構造をもつ

■ $Z = (z_1, z_2, \dots, z_k)$ を X と Y の任意の LCS とすると

① $x_m = y_n$ のとき、 $x_m = y_n = z_k$ で、
また、 $Z_{k-1} = (z_1, z_2, \dots, z_{k-1})$ は X_{m-1} と Y_{n-1} の LCS

— つまり、最後の文字が一致していれば、
 $x_m = y_n = z_k$ として LCS を 1 つ伸ばせる

② $x_m \neq y_n$ かつ $z_k \neq x_m$ ならば、 Z は X_{m-1} と Y の LCS

③ $x_m \neq y_n$ かつ $z_k \neq y_n$ ならば、 Z は X と Y_{n-1} の LCS

— つまり、一致していなければ、単にスキップ

LCSの長さについて成り立つ再帰式： 動的計画法により $O(mn)$ で計算できる

- X_i と Y_j とのLCSの長さを $c[i, j]$ とする

- $c[i, j] = \max$
$$\begin{cases} 0 & (i = 0 \text{ または } j = 0) \\ c[i - 1, j - 1] + 1 & (x_i = y_j) \leftarrow \textcircled{1} \\ \max\{c[i, j - 1], c[i - 1, j]\} & (x_i \neq y_j) \leftarrow \textcircled{2}\textcircled{3} \end{cases}$$

- $c[m, n]$ が $O(mn)$ で求まる

解の構成 :

実際の解はバックトラックで求まる

■ LCSはバックトラックで構成できる

—注 : LCSは複数ありうる
(最適な経路は複数ありうる)

■ 例 :

— $X = (a, b, c, b, d, a, b)$

— $Y = (b, d, c, a, b, a)$

— $Z = (b, c, b, a)$

