

統計的モデリング基礎⑨

～さまざまな確率モデル～

(ロジスティック回帰の発展と生存期間のモデル)

鹿島久嗣
(情報学科 計算機科学コース)

今回の話題：

さまざまな確率モデル

- ロジスティック回帰モデルの発展：
 - 多クラスロジスティック回帰モデル
 - 順序回帰モデル
 - ランキング（一対比較）モデル
 - ニューラルネットワーク
- 生存期間のモデル
 - ハザード関数
 - 生存期間モデルの最尤推定

ロジスティック回帰モデルの発展

ロジスティック回帰モデルの発展： 従属変数の型に合わせた発展


- 確率モデルはデータの生成モデル
- 分析対象のデータに合わせてモデルが変わる
 - 質的変数（ダミー変数0, 1）の場合：ロジスティック回帰モデル
→ 選択肢が複数の場合：多値ロジスティック回帰
 - 量的変数（連続値）の場合：線形回帰モデル
→ 順序尺度（例えば5段階評価）の場合：順序回帰
 - 比較：一対比較のモデル（例：2つのうちどちらがよいか？）
- 多層化による非線形モデルの実現：ニューラルネットワーク

ロジスティック回帰モデル： ダミー変数を従属変数とするモデル

- 従属変数 Y が（2値の）ダミー変数であるモデル
- ロジスティック回帰モデル： $Y = +1$ となる確率

$$P(Y = 1|\mathbf{x}, \boldsymbol{\beta}) = \frac{1}{1 + \exp(-\boldsymbol{\beta}^\top \mathbf{x})} = \sigma(\boldsymbol{\beta}^\top \mathbf{x})$$

- σ ：ロジスティック関数（ $\sigma: \mathbb{R} \rightarrow (0,1)$ ）



多値ロジスティック回帰モデル： 多値の従属変数を説明するモデル

- 従属変数 Y が多値である場合（ $Y \in \mathcal{Y} = \{1, 2, \dots, k\}$ ）

- ただし、 $1, 2, \dots, k$ の並び順に意味はないことに注意

- 多値ロジスティック回帰モデル： $Y = y$ である確率

- 各 $y \in \mathcal{Y}$ ごとにパラメータ $\boldsymbol{\beta}_y$ をもつ


いわゆるソフトマックス関数

$$P(Y = y | \mathbf{x}, \{\boldsymbol{\beta}_{y'}\}_{y' \in \mathcal{Y}}) = \frac{\exp(\boldsymbol{\beta}_y^\top \mathbf{x})}{\sum_{y' \in \mathcal{Y}} \exp(\boldsymbol{\beta}_{y'}^\top \mathbf{x})}$$

- $\mathcal{Y} = \{+1, -1\}$ のときは $\boldsymbol{\beta} = \boldsymbol{\beta}_{+1} - \boldsymbol{\beta}_{-1}$ とすると通常のロジスティック回帰に一致

多段ロジスティック回帰モデル： 多段に連結されたロジスティック回帰モデル

- 複数の連続した従属変数：
 - 階層的な分類（大カテゴリ→中カテゴリ→小カテゴリ）
 - 段階的な意思決定プロセス（購入の有無→商品）
- ロジスティック回帰モデルを連結する



順序回帰：


順序尺度をもつ従属変数を説明するモデル

この順序に意味がある場合
(5段階評価など)

- Y が多値で順序尺度をもつ場合 ($Y \in \mathcal{Y} = \{1, 2, \dots, k\}$)
- $Y \geq y$ となる確率を与えるモデルを考える：

$$P(Y \geq y | \mathbf{x}, \boldsymbol{\beta}) = \frac{1}{1 + \exp(-\boldsymbol{\beta}^\top \mathbf{x} + \alpha_y)} = \sigma(\boldsymbol{\beta}^\top \mathbf{x} - \alpha_y)$$

- パラメータ $\boldsymbol{\beta}$ は y によらず共通
- 「切片」が y ごとに異なる：
 $\alpha_1 \leq \alpha_2 \leq \dots \leq \alpha_k$
(平行移動)



順序回帰モデル：


順序尺度をもつ従属変数を説明するモデル

- 順序回帰モデルは $Y \geq y$ となる確率がロジスティック回帰モデル：

$$P(Y \geq y | \mathbf{x}, \boldsymbol{\beta}) = \sigma(\boldsymbol{\beta}^\top \mathbf{x} - \alpha_y)$$

- $Y = y$ である確率は上記モデルの差を用いて表現できる：

$$P(Y = y | \mathbf{x}, \boldsymbol{\beta}) = P(Y \geq y | \mathbf{x}, \boldsymbol{\beta}) - P(Y \geq y - 1 | \mathbf{x}, \boldsymbol{\beta})$$




ランキングの確率モデル： 一対比較のモデル

- 感性評価などは絶対評価を与えにくい
- 一対比較：「どちらがよいか」のほうが答えやすい
- データ*i*がデータ*j*よりも上位である（ $i > j$ ）確率：


$$P(i > j | \mathbf{x}^{(i)}, \mathbf{x}^{(j)}, \boldsymbol{\beta}) = \frac{\exp(\boldsymbol{\beta}^\top \mathbf{x}^{(i)})}{\exp(\boldsymbol{\beta}^\top \mathbf{x}^{(i)}) + \exp(\boldsymbol{\beta}^\top \mathbf{x}^{(j)})}$$
$$= \sigma(-\boldsymbol{\beta}^\top (\mathbf{x}^{(i)} - \mathbf{x}^{(j)}))$$

- 2つのデータの独立変数の差を、ペアに対する独立変数としたロジスティック回帰モデル




ニューラルネットワーク： ロジスティック回帰の多層化

- ロジスティック回帰は線形回帰モデルの出力に非線形写像を適用（ $(0,1)$ 区間への写像）



- ニューラルネットワークはこれを多層化し非線形性を導入したもの
 - 非線形写像は必ずしもロジスティック関数である必要はない



生存期間のモデル

生存期間のモデル： 期間を確率変数とするモデル

- 期間（非負の実数）を確率変数とするようなモデル：
 - 商品の寿命、患者の生存期間、...
 - 一方、ポアソン分布は回数（非零の整数）のモデル
- 生存期間の確率変数 T : $\Pr(T \leq t) = F(t) = \int_0^t f(\tau) d\tau$
 - 確率密度関数 $f(t)$: 時刻 t まで生存していて、時刻 $t + \Delta t$ までの間の死亡確率が $f(t)\Delta t$ （「時刻 t まで生存」かつ「 $t \sim t + \Delta t$ で死亡」）
 - ◆ $f(t) = \lim_{\Delta t \rightarrow 0} \frac{F(t+\Delta t) - F(t)}{\Delta t}$
 - $\Pr(T > t) = S(t) = 1 - F(t)$: 時刻 t 以降も生存する確率
(少なくとも時刻 t までは生存する)

生存関数

指数分布モデル： もっとも単純な生存期間のモデル

- $f(t)$: 時刻 t まで生存していて、時刻 $t + \Delta t$ までの間の死亡確率が $f(t)\Delta t$ (「時刻 t まで生存」かつ「 $t \sim t + \Delta t$ で死亡」)

- 指数分布モデル : $f(t) = \theta \exp(-\theta t)$


- $\theta > 0$: モデルパラメータ

- 生存期間 T :

$$\Pr(T \leq t) = F(t) = \int_0^t f(\tau) d\tau = 1 - \exp(-\theta t)$$

$$\blacklozenge E[T] = \frac{1}{\theta}, \text{Var}[T] = \frac{1}{\theta^2}$$

- 独立変数によってパラメータが変わる場合 : $\theta = \exp(\boldsymbol{\beta}^\top \mathbf{x})$



ハザード関数： ある時刻の死亡リスクを表す関数

- $f(t)$ は「時刻 t まで生存している」かつ「次の瞬間に死亡する」可能性を表す（ちょっと解釈しにくい）
- 瞬間瞬間の死亡リスクをみたほうがわかりやすい？
 - 「時刻 t まで生存している」という条件のもとでの「次の瞬間に死亡する」可能性（条件付確率）をみる

- ハザード関数：
$$h(t) = \frac{f(t)}{S(t)} = - \frac{d \log S(t)}{dt}$$

$S(t) = 1 - F(t)$:
生存関数（少なくとも時刻 t までは生存する確率）

- ハザード関数の時間変化：

$\frac{dh(t)}{dt} > 0$ のとき、リスクが時間とともに増加（ < 0 であれば減少）

ワイブル分布： 指数分布の一般化

- 指数分布モデルはリスクが時間に関わらず一定

- 指数分布のハザード関数：
$$h(t) = \frac{f(t)}{S(t)} = \frac{\theta \exp(-\theta t)}{\exp(-\theta t)} = \theta \text{ (定数)}$$

- ワイブル分布モデル：


$$f(t) = \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1} \exp\left\{-\left(\frac{t}{\lambda}\right)^k\right\}, k, \lambda > 0$$

- $k = 1$ のとき指数分布 ($\theta = 1/\lambda$)

$$f(t) = \theta \exp(-\theta t)$$

- 独立変数を取り込む場合：

$$\lambda = \exp(\boldsymbol{\beta}^\top \mathbf{x})$$



https://en.wikipedia.org/wiki/Weibull_distribution#/media/File:Weibull_PDF.svg

ワイブル分布：

パラメータによってハザード関数の時間的増減が決まる

- ワイブル分布の生存関数：

$$S(t) = \int_t^{\infty} \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1} \exp \left\{ - \left(\frac{t}{\lambda}\right)^k \right\} dt = \exp \left\{ - \left(\frac{t}{\lambda}\right)^k \right\}$$


- ハザード関数： $h(t) = \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1}$

- $k = 1$ のとき $h(t) = 1/\lambda$

- $k > 1$ のとき $\frac{dh(t)}{dt} > 0$

- $k < 1$ のとき $\frac{dh(t)}{dt} < 0$

k によって決まる



生存時間モデルの最尤推定：

生存期間の確率密度関数 $f(t)$ を最尤推定

■ データ $\{t^{(1)}, t^{(2)}, \dots, t^{(N)}\}$:

• N 個の独立な観測（生存期間がちょうど $t^{(i)}$ ）

■ 尤度関数 $L(\theta) = \prod_{i=1}^N f(t^{(i)})$

言い換えれば、 $t^{(i)}$ まで生きていて
次の瞬間死亡したという観測データ

• 確率密度関数 $f(t)$ ：時刻 t まで生存していて、時刻 $t + \Delta t$ までの間の死亡確率が $f(t)\Delta t$

• 指数分布モデルの場合： $L(\theta) = \prod_{i=1}^N \theta \exp(-\theta t^{(i)}) \Delta t$

◆ 対数尤度にすると $\log L(\theta) = N \log \theta - \theta \sum_{i=1}^N t^{(i)}$

◆ 最尤推定量は $\hat{\theta} = \frac{N}{\sum_{i=1}^N t^{(i)}}$

打ち切りがある場合の最尤推定：

打ち切りデータに対して生存関数 $S(t)$ を当てはめる

- データ $\{t^{(1)}, t^{(2)}, \dots, t^{(N)}\} \cup \{s^{(1)}, s^{(2)}, \dots, s^{(M)}\}$:

- N 個の生存期間データに加えて、
 M 個の打ち切りデータ（少なくとも $s^{(i)}$ 期間生存）


- 尤度関数：

$$L(\theta) = \prod_{i=1}^N f(t^{(i)}) \cdot \prod_{j=1}^M S(t^{(j)})$$

- 生存関数 $S(t) = \int_t^{\infty} f(t) dt$:
少なくとも t 期間は生存している確率

- 指数分布の場合： $S(t) = \exp(-\theta t)$

- ◆ $\log L(\theta) = N \log \theta - \theta \left(\sum_{i=1}^N t^{(i)} + \sum_{j=1}^M s^{(j)} \right)$



今回の話題：

さまざまな確率モデル

- ロジスティック回帰モデルの発展：
 - 多クラスロジスティック回帰モデル
 - 順序回帰モデル
 - ランキング（一対比較）モデル
 - ニューラルネットワーク
- 生存期間のモデル
 - ハザード関数
 - 生存期間モデルの最尤推定