

統計的モデリング基礎⑪


～ベイズモデリング（続き）と生存期間のモデル～

鹿島久嗣
(情報学科 計算機科学コース)

ベイズモデリングの応用

インターネット広告： あらゆる場所に潜むオンライン広告

- インターネット上は広告だらけ
 - Webページ上のバナー広告、検索エンジンのリスティング広告、...
- 多くのWeb系企業の主要なビジネスモデル
 - 広告表示・クリック・成約等に応じた課金
 - アフィリエイト収入



電通「2025年 日本の広告費」 https://www.dentsu.co.jp/knowledge/ad_cost/2025/より作成

ネット広告配信の最適化： 適切な広告を 適切な人に届ける

- ネット広告の特徴：
 - 細かい配信調整ができる
 - ◆ ページ閲覧ごとに別の広告を提示できる
 - 効果が測定しやすい
 - ◆ 誰が広告をみて商品を買ったかがデータとして取得できる
- 細かい配信最適化によって広告の効果を最大化する
 - どの広告を提示するべきか（← この問題を考えてみる）
 - 誰に広告を提示すべきか
 - どこに広告を出すべきか


提示する広告選択の最適化： 広告効果を推定して効果の高い広告に集中投下

- 広告配信の最適化問題：
 - 100種類の広告から100万回配信する
 - 広告がクリックされる回数を最大化したい
- 各広告の効果（クリック率）は未知
 - 実際に広告を配信してみないと広告の効果はわからない
- 推定と利用のトレードオフ
 1. 推定：すべての広告をまんべんなく配信し、クリック率を推定
 2. 利用：クリック率が高いものを集中的に配信の両者をバランスよく行う必要がある



バンディット問題： 広告配信最適化問題のモデル

- バンディット問題：
 - 当たりの確率が不明な複数のスロットマシンがある
 - 1回につきひとつのスロットマシンを選んでプレイ
 - 当たり回数を最大化したい
- 広告配信最適化問題はバンディット問題として定式化できる
- ポイント：
推定と利用のバランスをいかにとるか



http://en.wikipedia.org/wiki/File:Las_Vegas_slot_machines.jpg

バンディット問題のモデル化：

各スロットマシンが未知の当たり確率をパラメータとしてもつ

- m 台のスロットマシンがある
- スロットマシン i の当たり確率は θ_i （未知）とする
 - つまり、スロットマシンの当たりをベルヌイ分布としてモデル化する
- データ：スロットマシン i をこれまでに n_i 回プレイして h_i 回当たった
- 次にどのマシンをプレイすべきかを決定する問題



スロットマシン1
当たり確率 θ_1



スロットマシン2
当たり確率 θ_2


...



スロットマシン m
当たり確率 θ_m

バンディット問題の問題： 推定精度のばらつき

- 当たり確率の最尤推定値は $\hat{\theta}_i = \frac{h_i}{n_i}$ なので、 $\hat{\theta}_i$ が最大のスロットマシンをプレイすればよいだろうか？
- でも、当たり確率の推定値が同じでも、過去のプレイ回数が多い（少ない）ほど推定値の信頼度は高い（低い）はず...




当たり確率のベイズモデリング： 推定精度を考慮した当たり確率の推定

- 当たり確率の推定値のばらつきをベイズモデリングによって考慮する
- 当たり確率の事後分布は $P(\theta_i | n_i, h_i)$
 - マシン i をこれまでに n_i 回プレイして h_i 回当たったという状況
 - 事後分布の広がり具合が推定の曖昧さに対応
- 例によってベイズの定理を用いると：

$$P(\theta_i | n_i, h_i) = \frac{P(n_i, h_i | \theta_i)P(\theta_i)}{\int_0^1 P(n_i, h_i | \theta_i)P(\theta_i)d\theta_i}$$

事前分布



当たり確率の事前分布：

ベータ分布はベルヌイ分布の共役事前分布

- 事前分布をベータ分布とする：

$$P(\theta_i) = \frac{1}{B(\alpha, \beta)} (\theta_i)^{\alpha-1} (1 - \theta_i)^{\beta-1}$$

ディリクレ分布で
 $k = 2$ の場合に相
当

- ベータ関数 $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$


$$\frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} = \int_{\theta_i} (\theta_i)^{\alpha-1} (1 - \theta_i)^{\beta-1} \theta_i$$

- 分散は $\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$

(α, β が大きくなると小さくなる)

- ディリクレ分布の特殊（2値）ケース

確率密度関数



https://en.wikipedia.org/wiki/Beta_distribution#/media/File:Beta_distribution_pdf.svg

当たり確率の事後分布： 事後分布もベータ分布になる

- 事後分布はベータ分布になる（共役事前分布）：

$$P(\theta_i | n_i, h_i) = \frac{1}{B(h_i + \alpha, n_i - h_i + \beta)} (\theta_i)^{h_i + \alpha - 1} (1 - \theta_i)^{n_i - h_i + \beta - 1}$$

- 導出：

$$\begin{aligned} P(\theta_i | n_i, h_i) &\propto P(n_i, h_i | \theta_i) P(\theta_i) \\ &= (\theta_i)^{h_i} (1 - \theta_i)^{n_i - h_i} \frac{1}{B(\alpha, \beta)} (\theta_i)^{\alpha - 1} (1 - \theta_i)^{\beta - 1} \\ &= \frac{1}{B(\alpha, \beta)} (\theta_i)^{h_i + \alpha - 1} (1 - \theta_i)^{n_i - h_i + \beta - 1} \end{aligned}$$

$$\frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} = \int_{\theta_i} (\theta_i)^{\alpha - 1} (1 - \theta_i)^{\beta - 1} \theta_i$$

改めて $\frac{1}{B(h_i + \alpha, n_i - h_i + \beta)}$ で正規化すると上記の結果が得られる

次にプレイするマシンの決定：

事後分布から最も当たり確率が高そうなマシンをプレイ

- 戦略：

マシン i の当たり確率 θ_i が全マシンの中で最も高くなる確率 π_i に従ってマシンを選択する：

$$\pi_i = \Pr \left[\theta_i \geq \theta_j, \forall j \neq i \mid \{n_i, h_i\}_{i=1, \dots, m} \right]$$

- しかし、 π_i を解析的に直接評価することは困難

- サンプルングで解決：

実際に事後分布 $P(\theta_i \mid n_i, h_i)$ を使って θ_i ($i = 1, 2, \dots, m$) をサンプルングしてみて、その中で一番大きい θ_i を採用する

- 棄却サンプリング： $[0, 1]$ の一様乱数 θ_i を発生させ、別の一様乱数 $M \in [0, 1]$ が $P(\theta_i \mid n_i, h_i)$ より小さければ θ_i を採用する

トンプソン抽出：

サンプリングによって次のマシンを選択する

- 「スロットマシン i の値が最も高い確率」は直接評価が困難：
$$\Pr[P(\theta_i \mid n_i, h_i) > P(\theta_j \mid n_j, h_j), \forall j \neq i]$$

- トンプソン抽出：サンプリングで解決する

1. 各マシンの当たり確率の事後分布に基づいて当たり確率 $\{\theta_i\}_{i=1,\dots,m}$ をサンプリングする
2. θ_i が一番大きいスロットマシンを選ぶ
※ ここまでがマシンの決定に関する部分
3. 結果に基づき θ_i の事後分布を更新
※ n_i, h_i が更新されることに伴って事後分布が変わり
次の決定に影響する

まとめ： ベイズモデリング

■ ベイズ統計

- 事前分布 + データ（証拠） = 事後分布

■ ベイズモデリング

- ディリクレ分布を共役事前分布とした離散分布のベイズ推定
- 階層ベイズモデリングによるモデルの抽象化
- 経験ベイズ法による超パラメータの推定

■ 広告配信最適化問題への応用：

- バンディット問題としての定式化
- ベイズ事後分布によって、当たり確率の推定のばらつきを考慮
- トンプソン抽出による、情報の獲得と利用をバランスした、効率的な決定

生存期間モデリング

生存期間モデリング： 期間（非負の実数）を確率変数とするモデルとその推定

- 生存期間のモデル
- ハザード関数
- 生存期間モデルの最尤推定

生存期間のモデル： 期間を確率変数とするモデル

- 期間（非負の実数）を確率変数とするようなモデル：
 - 商品の寿命、患者の生存期間、...
 - 一方、ポアソン分布は回数（非零の整数）のモデル
- 生存期間の確率変数 T : $\Pr(T \leq t) = F(t) = \int_0^t f(\tau) d\tau$
 - 確率密度関数 $f(t)$: 時刻 t まで生存していて、時刻 $t + \Delta t$ までの間の死亡確率が $f(t)\Delta t$ （「時刻 t まで生存」かつ「 $t \sim t + \Delta t$ で死亡」）
 - ◆ $f(t) = \lim_{\Delta t \rightarrow 0} \frac{F(t+\Delta t) - F(t)}{\Delta t}$
 - $\Pr(T > t) = S(t) = 1 - F(t)$: 時刻 t 以降も生存する確率
(少なくとも時刻 t までは生存する)

生存関数

指数分布モデル： もっとも単純な生存期間のモデル

- $f(t)$: 時刻 t まで生存していて、時刻 $t + \Delta t$ までの間の死亡確率が $f(t)\Delta t$ (「時刻 t まで生存」かつ「 $t \sim t + \Delta t$ で死亡」)

- 指数分布モデル : $f(t) = \theta \exp(-\theta t)$


- $\theta > 0$: モデルパラメータ

- 生存期間 T :

$$\Pr(T \leq t) = F(t) = \int_0^t f(\tau) d\tau = 1 - \exp(-\theta t)$$

$$\blacklozenge E[T] = \frac{1}{\theta}, \text{Var}[T] = \frac{1}{\theta^2}$$

- 独立変数によってパラメータが変わる場合 : $\theta = \exp(\boldsymbol{\beta}^\top \mathbf{x})$



ハザード関数： ある時刻の死亡リスクを表す関数

- $f(t)$ は「時刻 t まで生存している」かつ「次の瞬間に死亡する」可能性を表す（ちょっと解釈しにくい）
- 瞬間瞬間の死亡リスクをみたほうがわかりやすい？
 - 「時刻 t まで生存している」という条件のもとでの「次の瞬間に死亡する」可能性（条件付確率）をみる
- ハザード関数：
$$h(t) = \frac{f(t)}{S(t)} = - \frac{d \log S(t)}{dt}$$

$S(t) = 1 - F(t)$:
生存関数（少なくとも時刻 t までは生存する確率）
- ハザード関数の時間変化：
 $\frac{dh(t)}{dt} > 0$ のとき、リスクが時間とともに増加（ < 0 であれば減少）

ワイブル分布： 指数分布の一般化

- 指数分布モデルはリスクが時間に関わらず一定

- 指数分布のハザード関数：
$$h(t) = \frac{f(t)}{S(t)} = \frac{\theta \exp(-\theta t)}{\exp(-\theta t)} = \theta \text{ (定数)}$$

- ワイブル分布モデル：


$$f(t) = \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1} \exp\left\{-\left(\frac{t}{\lambda}\right)^k\right\}, k, \lambda > 0$$

- $k = 1$ のとき指数分布 ($\theta = 1/\lambda$)

$$f(t) = \theta \exp(-\theta t)$$

- 独立変数を取り込む場合：

$$\lambda = \exp(\boldsymbol{\beta}^\top \mathbf{x})$$



https://en.wikipedia.org/wiki/Weibull_distribution#/media/File:Weibull_PDF.svg

ワイブル分布：

パラメータによってハザード関数の時間的増減が決まる

■ ワイブル分布の生存関数：

$$S(t) = \int_t^{\infty} \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1} \exp \left\{ - \left(\frac{t}{\lambda}\right)^k \right\} dt = \exp \left\{ - \left(\frac{t}{\lambda}\right)^k \right\}$$


■ ハザード関数： $h(t) = \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1}$

- $k = 1$ のとき $h(t) = 1/\lambda$

- $k > 1$ のとき $\frac{dh(t)}{dt} > 0$

- $k < 1$ のとき $\frac{dh(t)}{dt} < 0$

k によって決まる



生存時間モデルの最尤推定： 生存期間の確率密度関数 $f(t)$ を最尤推定

■ データ $\{t^{(1)}, t^{(2)}, \dots, t^{(N)}\}$:

• N 個の独立な観測（生存期間がちょうど $t^{(i)}$ ）

■ 尤度関数 $L(\theta) = \prod_{i=1}^N f(t^{(i)})$

言い換えれば、 $t^{(i)}$ まで生きていて
次の瞬間死亡したという観測データ

• 確率密度関数 $f(t)$: 時刻 t まで生存していて、時刻 $t + \Delta t$ までの間の死亡確率が $f(t)\Delta t$

• 指数分布モデルの場合 : $L(\theta) = \prod_{i=1}^N \theta \exp(-\theta t^{(i)}) \Delta t$

◆ 対数尤度にすると $\log L(\theta) = N \log \theta - \theta \sum_{i=1}^N t^{(i)}$

◆ 最尤推定量は $\hat{\theta} = \frac{N}{\sum_{i=1}^N t^{(i)}}$

打ち切りがある場合の最尤推定：

打ち切りデータに対して生存関数 $S(t)$ を当てはめる

- データ $\{t^{(1)}, t^{(2)}, \dots, t^{(N)}\} \cup \{s^{(1)}, s^{(2)}, \dots, s^{(M)}\}$:

- N 個の生存期間データに加えて、
 M 個の打ち切りデータ（少なくとも $s^{(i)}$ 期間生存）


- 尤度関数：

$$L(\theta) = \prod_{i=1}^N f(t^{(i)}) \cdot \prod_{j=1}^M S(t^{(j)})$$

- 生存関数 $S(t) = \int_t^{\infty} f(t) dt$:
少なくとも t 期間は生存している確率

- 指数分布の場合： $S(t) = \exp(-\theta t)$

- ◆ $\log L(\theta) = N \log \theta - \theta \left(\sum_{i=1}^N t^{(i)} + \sum_{j=1}^M s^{(j)} \right)$



まとめ：

生存期間のモデルは期間（非負の実数）を扱うモデル

- 生存期間のモデル：指数分布、ワイブル分布、...
- ハザード関数：ある時点におけるリスクを表す
- 生存期間モデルの最尤推定：打ち切りがある場合に注意