

統計的モデリング基礎⑫ ～因果推論～

鹿島久嗣
(情報学科 計算機科学コース)

今回の話題： 因果推論

- 相関関係と因果関係は異なるという話：相関 $\neq$ 因果
- 因果関係の定量化
- ランダム化試験（RCT）：因果関係を調べる方法
- 観察データから因果関係を推定する方法



一般書



教科書





因果関係

相関と因果： これは因果関係？

- 警察官を増やすと、犯罪率が上がる？
 - 回帰モデル： 犯罪率(%) = $3 \times$ 警察官の人数(千人)
 - 警察官を1,000人増やすと、犯罪率が3%上がるのか？

実際には、犯罪発生件数が**多いから**
警察官を多く配置している




- 握力を上げると、学力が上がる？
 - テストの点 = $3 \times$ 握力
 - 握力を1kgw増やせば3点増える？


相関と因果：

相関と因果は異なる

- 相関は必ずしも因果を意味しない
 - 相関：片方の変数の大小関係と、もう片方の変数の大小関係が関係している（片方がわかると、もう片方についてわかる）
 - 因果：片方の変数を変化させると、もう片方の変数も変化する



- 観察と介入の違い
 - 相関があれば、観察をもとに予測ができる
 - 因果があれば、介入によって操作ができる



相関≠因果： まったくの偶然によっても起きる



— 米国の科学技術予算

— 首吊り自殺者の数

— プールでの溺死者数

— ニコラス・ケイジの出演映画数

— ミス・アメリカの年齢

— 暖房器具が原因の死者数

<https://tylervigen.com/spurious-correlations>


交絡：

共通の別要因によって、相関が生じる



- 交絡因子：原因変数と結果変数に影響を与える

- 例 1：握力があがると学力が上がる？

- 握力と学力の間に相関がある
- 実際には学年が交絡因子になっている
 - ◆ 学年を固定すると無相関



- 例 2：海外留学をすると、就職に有利？




相関≠因果が生じるケース：


偶然や逆向きの因果、共通の要因（交絡）などによる

■ 因果関係がないのに相関が生じるケース：

- まったくの偶然
- 逆向きの因果関係（→ 警察官の例）
- 交絡：別の（共通の）要因がある



■ 「因果ダイアグラム」で表現




因果関係の定量化

介入効果： 因果関係の有無・強さの定量化

- 全く同じ状況において「介入を受けた場合」と「介入を受けなかった場合」の結果の違いが介入による因果的な効果を表す
- i さんが介入を受けた場合の結果変数 Y_i^T と、受けなかった場合の結果変数 Y_i^C の差 $Y_i^T - Y_i^C$ が i さんへの（個別）介入効果

※ T : Treatment C : Control



平均介入効果：

母集団に対する平均的な介入効果で測る

- i さんが介入を受けた場合の結果変数 Y_i^T と、受けなかった場合の結果変数 Y_i^C の差 $Y_i^T - Y_i^C$ が i さんへの介入による（個別）効果

※ T : Treatment C : Control

- 母集団全体に対してどの程度効果があったか？
母集団に対する平均的な介入効果を因果関係の強さとする：

$$E[Y^T - Y^C]$$

これを推定するのが目的

- ※ ひとまず介入は2値（介入するT /しないC）とする
介入が量的変数の場合は、介入 Z と結果 Y に線形の関係を保定して
 $E[Y(Z)] - E[Y(0)] = \beta Z$ であるときの β を見たりする

因果関係の推定：

平均介入効果は直接計測できない

- 我々の知りたい因果関係の強さ： $E[Y^T - Y^C]$
- これは、 $\frac{1}{n} \sum_i (Y_i^T - Y_i^C)$ で推定できそうだが...？
 - $Y_i^T - Y_i^C$ は直接観測できない：介入の有無はどちらか一方のみが実現するので、 Y_i^T と Y_i^C のいずれか一方のみ観測可能
 - ◆ 観測されないほうの結果を「反事実」とよぶ
- では、 $E[Y^T - Y^C] = E[Y^T] - E[Y^C]$ なので、介入群と対照群からそれぞれ $E[Y^T]$ と $E[Y^C]$ を推定すればよい？
→ これもダメ💀(介入に「バイアス」がありうるから)
- 推定できるのは $E[Y^T | Z = T]$ と $E[Y^C | Z = C]$

介入群
 $Z = T$



対照群
 $Z = C$



例：


$$E[Y^T \mid Z = T] - E[Y^C \mid Z = C] \neq E[Y^T] - E[Y^C]$$

ID	Z	Y^T	Y^C	Y	効果	$Y Z = T$	$Y Z = C$
1	T	1	1	1	0	1	
2	T	1	1	1	0	1	
3	T	1	0	1	1	1	
4	T	1	0	1	1	1	
5	C	1	0	0	1		0
6	C	1	0	0	1		0
7	C	0	1	1	-1		1
8	C	0	1	1	-1		1
9	T	0	0	0	0	0	
10	C	0	0	0	0		0
平均	0.5	0.6	0.4	0.6	0.2	0.8	0.4

介入のバイアス：

データ収集の際の介入判断の偏りが推定を偏らせる

- 過去のデータには、その時の介入判断に偏りがある
 - いかにも買いそうな人に割引券を発行した（or その逆）
- 偏ったデータからは偏った因果効果が導かれうる
 - 効果を過大評価・過小評価する恐れ
 - 理想的にはランダムに介入された（RCT）データが必要



介入のバイアス：

介入判断の偏りが、介入効果の推定を偏らせる

- それぞれの対象に対して、
介入する ($Z = T$) か介入しない ($Z = C$) かが決まるとする
- 我々が直接推定できるのは、母集団において
 - 介入した人 ($Z = T$) に介入した結果 (Y^T)
 - 介入しなかった人 ($Z = C$) に介入しなかった結果 (Y^C)

の平均的な差のみ：

$$E[Y^T \mid Z = T] - E[Y^C \mid Z = C] \quad (\neq E[Y^T] - E[Y^C])$$

この等号は一般には成り立たない

本当に推定したいもの

- この値が非零だからといって、因果関係があるとは限らない
- データ量を増やすだけでは、因果関係は明らかにならない


ランダム化試験による因果関係の計測

因果関係を導くためには：

介入変数の割り付けと交絡因子の関連を切る

- 真の因果関係を導くには、交絡因子の影響を切る必要がある
 - データを増やしても、交絡によるバイアスは消えない
- 例：ある最新の治療法を実施したほうが、死亡率が高い？
 - ◆ 因果関係：「最新の治療法はむしろ死亡率を上げている」？
 - ◆ 交絡：そもそも難病患者にのみ治療法を適用している可能性（難病患者かどうかが交絡因子）


の2つを区別する必要がある



ランダム化試験（RCT）：


介入を交絡因子と独立にすることで交絡因子の影響を切る

- 因果効果がただしく推定されるためには...：
 - 介入変数の割り付けを交絡因子と独立にする
 - または、交絡因子を固定する
 - 介入変数と結果変数以外の変数の分布を、介入群と対照群で同一にする
- ランダム化試験（Randomized Controlled Trial; RCT）：
 - 介入群と対照群をランダムに割りつける
 - 介入と交絡因子が独立になる



ランダム化試験（RCT）のやり方： 対象者の特性によらず、ランダムに介入を割り付ける

- ランダム化試験（Randomized Controlled Trial; RCT）：
 - 対象をランダムに2つのグループに分ける
 - 片方のグループを介入群に、もう一方のグループを対照群として前者にのみ介入を行う
 - それぞれの群の結果を比較する
- A/BテストはRCT



Source: <http://kylerush.net/blog/optimization-at-the-obama-campaign-ab-testing/>

ランダム化の効果： 平均介入効果が正しく計測可能

- ランダム化の効果：因果関係が測れる！

$$E[Y^T \mid Z = T] - E[Y^C \mid Z = C] = E[Y^T] - E[Y^C] = E[Y^T - Y^C]$$

一般には等号は成り立たない

- Z は潜在結果 Y^T と Y^C と独立になるので、
 $E[Y^T \mid Z = T] = E[Y^T], E[Y^C \mid Z = C] = E[Y^C]$
- たとえ交絡因子が観測されていなくても、ランダム化によって介入の割り付けと交絡因子は独立になる

RCTの限界：

RCTは理想的な因果推論手法だが、実行困難な場合あり

■ ランダム化試験（RCT）：

- 介入群と対照群を「ランダムに」割り付け、結果を比較する
- 最も強力で汎用的な手法のひとつ
- 因果関係を導くことができる
- 交絡因子が未知でも実施できる

■ しかし、いつでもRCTができるわけではない...：

- そもそもできない（倫理的にできないなど）
- ランダムに割り付けても、そのとおりに介入を受けないことがある
 - ◆ 指示を出したのに実行しない（ノンコンプライアンス） など

観察データからの因果推論



観察データからの因果推論： すでにあるデータから因果関係を導く

- すでにあるデータから因果関係を導きたい
 - 必ずしもRCTによるデータではない
- 観測された交絡因子を調整し介入群と対照群を比較可能にする
 - あたかもRCTが行われたかのような状況を作り出す
 - 交絡因子を固定する、反事実を疑似的に作り出す、など
 - ◆ 層別解析、マッチング、傾向スコア、逆確率重みづけ

基本方針：

交絡因子の値が同じ対象同士で介入群と対照群を比較

- 結果変数の変化は、原因変数の変化によるものか、それとも交絡因子の変化によるものか？
- 握力と学力のケースでは、学年が交絡因子だった
 - 交絡因子を固定すれば、握力と学力の関係がみえるはず
- 層別解析：交絡因子を固定することによって、交絡因子の影響を除く
 - 学年ごとにデータを分けて相関をみる



マッチング

反事実：

反事実がわかれば因果効果が測れる（が不可能）

- 全く同じ状況における
 - 介入を受けた場合の結果
 - 介入を受けなかった場合の結果の差を介入の因果効果として定義した
- 反事実：「実際には起こらなかったが、もし起こっていたら...」
 - 実際には薬を飲んで風邪が治ったが、もし飲まなかったとしたら...
 - ◆ 治った⇒薬の効果は関係ない（因果関係なし）
 - ◆ 治らなかった⇒薬が効いた（因果関係あり）
- 反事実は観測されない：「あちら側」の世界の出来事




マッチング： 反事実の仮想的実現

- データの中から反事実ペアを見つける
 - (20代, 男性, 京都在住, 介入あり) と
(20代, 男性, 京都在住, 介入なし)は互いに反事実とみなせる
 - これらの結果の差は因果効果とみなしてよいのでは…？
- マッチング：介入変数以外の（交絡因子を含む）変数がすべて一致しているデータ同士を見つけてペアにする
 - 実現されない反事実を仮想的に実現する



(20代, 男性, 京都市在住, 介入あり) → 成績向上



(20代, 男性, 京都市在住, 介入なし) → 成績停滞

この差が
因果効果

反事実ペアの発見： 実際には近いペアで代用することも

- 実際には完全一致ペアを見つけるのは困難
- 代わりに「概ね一致」しているペアを見つける

(20歳, 男性, 京都市左京区在住, **介入あり**)



概ね一致



概ね一致

(21歳, 男性, 京都市上京区在住, **介入なし**)



- 2つのデータ $\mathbf{x} = (x_1, x_2, \dots, x_D)^\top$, $\mathbf{y} = (y_1, y_2, \dots, y_D)^\top$ の距離
 - $D(\mathbf{x}, \mathbf{y}) = |x_1 - y_1| + \dots + |x_D - y_D|$ (絶対距離)
 - $D(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + \dots + (x_D - y_D)^2}$ (ユークリッド距離)
 - $D(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \mathbf{y})}$ (マハラノビス距離)
 - ◆ 標準偏差で割って正規化するなども

傾向スコア

傾向スコア：

マッチングの「次元の呪い」問題を解決する

- 次元の呪い：変数が多いとマッチングが困難になる
 - 最新医療の導入と死亡率の間の因果関係の例だと、患者の難病度合いの他、年齢や、病院に機器があるか等の変数がありうる
- 傾向スコア $\Pr[Z = T \mid X]$ の導入：介入群への割付け確率
 - X ：介入変数・結果変数以外の変数（マッチングに使う変数）
 - たとえばロジスティック回帰モデルによる傾向スコアの定義：

$$P(Z = T \mid X = \mathbf{x}) = \frac{1}{1 + \exp(-\boldsymbol{\beta}^\top \mathbf{x})} = \sigma(\boldsymbol{\beta}^\top \mathbf{x})$$

$\boldsymbol{\beta}$ ：パラメータ

- 多変数を1次元の変数（傾向スコア）に縮約するイメージ

※ 観測されていない交絡がなく、介入確率が0または1でないことを仮定

傾向スコアの使い方①： マッチングにおける次元の呪いの解消

- 傾向スコア $\Pr[Z = T \mid X]$ （介入確率）をどう使うか？
- $\Pr[Z_i = T \mid X_i] \approx \Pr[Z_j = T \mid X_j]$ となる2つのデータ i と j があったとすると、介入の観点において、これらを同一視する
- 傾向スコア（1次元）をマッチングに用いる：
 - 傾向スコアが $\Pr[Z_i = T \mid X_i] \approx \Pr[Z_j = T \mid X_j]$ であり、実際には $Z_i = T$ 、 $Z_j = C$ であった2つのデータ i と j をマッチングする

傾向スコアの使い方①： マッチングの例

- 傾向スコア（1次元）をマッチングに用いる
- 例：介入（最新医療適用）を説明するモデルを推定：
$$\Pr[Z = \text{適用} \mid X = (\text{患者は難病か}, \text{年齢}, \text{機器の有無})]$$
- $\Pr[Z = \text{適用} \mid X]$ をマッチングの指標として利用する
（一次元なのでマッチングが行いやすい）
- （ほぼ）同じ割り付け確率をもちながら、実際に介入された人とされなかった人を比較する
- ◆ $\Pr[Z_i = \text{適用} \mid X_i] \approx \Pr[Z_j = \text{適用} \mid X_j]$ であり、実際には $Z_i = \text{適用}$ 、 $Z_j = \text{不適用}$ である2つのデータ i と j をマッチング

傾向スコアの使い方②： 逆確率重みづけ

- 全てのデータが同じ確率 $\Pr[Z = T | X] = 1/2$ で割りつけられたとみなせれば、RCTと同じとみなせるだろう
 - $\Pr[Z = T | X] = 1/2$ であるデータは、どちらに割り付けられるかが50:50 – つまりランダム化試験の結果とみなしてよいのでは？
 - ただし、この条件を満たすデータは多くないだろう...
- 逆確率重みづけ：傾向スコアの逆数で重みづける
 - $Z_i = T$ である i は $\frac{1/2}{\Pr[Z_i=T|X_i]}$ 個分と数える
 - $Z_i = C$ である i は $\frac{1/2}{1-\Pr[Z_i=T|X_i]}$ 個分と数える

傾向スコアの使い方②： 逆確率重みづけ

■ 逆確率重みづけ：傾向スコアの逆数で重みづける

- $Z_i = T$ であるデータ i は $\frac{1/2}{\Pr[Z_i=T|X_i]}$ 個分と数える
- $Z_i = C$ であるデータ i は $\frac{1/2}{1-\Pr[Z_i=T|X_i]}$ 個分と数える

■ その心は...：

- いま、 $\Pr[Z_i = T | X_i] = \frac{1}{2}$, $\Pr[Z_j = T | X_j] = 1/4$ なるデータ i と j があるとすると、 j は i よりも2倍くらい $Z = T$ になりにくい
- これを補正するためには「 j は i の2個分」と考えればよいのでは？

傾向スコアの使い方②： 逆確率重みづけの計算例

- 傾向スコアが与えられたデータ：

患者ID	介入	結果	傾向スコア	重み
1	あり(1)	治癒(1)	$1/3$	$3/2$
2	あり(1)	治癒せず(0)	$3/4$	$2/3$
3	なし(0)	治癒(1)	$1/2$	1
4	なし(0)	治癒せず(0)	$2/3$	$3/2$
5	なし(0)	治癒(1)	$1/4$	$2/3$

- 介入群の結果の期待値： $1 \cdot \frac{\frac{3}{2}}{\frac{3}{2} + \frac{2}{3}} + 0 \cdot \frac{\frac{2}{3}}{\frac{3}{2} + \frac{2}{3}} = \frac{9}{13}$
 - 非介入群の結果の期待値： $1 \cdot \frac{1 + \frac{2}{3}}{1 + \frac{3}{2} + \frac{2}{3}} + 0 \cdot \frac{\frac{3}{2}}{1 + \frac{3}{2} + \frac{2}{3}} = \frac{10}{19}$
- 平均介入効果： $\frac{9}{13} - \frac{10}{19} = \frac{41}{247}$

今回の話題： 因果推論

- 相関関係と因果関係は異なるという話：相関 $\neq$ 因果
- ランダム化試験（RCT）：因果関係を導く最も正しいやり方
- すでにあるデータから因果を導くにはどうしたらよいか
 - 層別解析、マッチング、傾向スコア、逆確率重みづけ

補遺：異常検知

※ 時間があれば扱う／講義では扱わない補足資料

障害や災害：

大規模で複雑なシステムの障害は一旦起こると大損失

生産ラインの故障



コンピュータの
ウィルス感染・不正侵入



ほか、カード不正使用、オレオレ詐欺、監視カメラ,...

監視システム： 障害の予兆を早期発見できれば対処可能




まだ間に合う！



異常検知：

システムの問題を事前に察知し知らせる


- 設置されたセンサーからの取得データをもとに異常を早期検知したい



異常検知の難しさ：

障害のデータがないため、判別モデルが適用できない

- 障害発生時のデータが集められる場合：
 - 予め検出したいタイプの異常がわかっている場合
 - ある程度の頻度で起こる場合
- 判別モデル（ロジスティック回帰等）が適用可能



- しかし、重大な障害ほど初めて出会うものが多い
- 過去のデータがない（判別モデルが使えない）

異常検知の考え方：

正常時を捉え、そこからの逸脱を見つける

■ 文書や会話：

- 正常：よく出てくる単語・表現
- 異常：めったに出てこない単語・表現

■ センサー：

- 正常：普段の値の範囲
- 異常：普段では出てこない値




異常検知技術：

「普通でない」データのパターンをみつけたす技術

- 異常：データの中に含まれる「普通でない」パターン
 - 対象のシステムのなんらかの異常を原因として表れる
 - ◆ クレジットカード不正使用・システム侵入・テロ
・システムダウン...
 - あるいは対象システムの状態変化
 - ◆ 新規ニューストピック出現・システムの設定変更
・環境変化...
- これらをデータの中から発見し報告するのが異常検知

異常検知の基本的な考え方： 稀な値を異常と考える

- 単純な場合として1変数（例えば温度）を対象とした異常検知を考える
- 通常値の範囲をとらえる（温度は通常20～50℃の間）
- そこから逸脱した値を検出し、異常として報告する
（80℃はふつうでない）



統計的な異常検知：

モデルからの生成確率が小さいデータを異常と考える

- 正常なデータ $x_1, x_2, \dots, x_n$ が与えられる
- 正常なデータからモデル $p(x)$ を推定する
 - たとえば最尤推定によって（正常時モデルの）パラメータ推定値を得る
- 検証対象のデータ x^{NEW} に対して、モデルが与える確率 $p(x^{\text{NEW}})$ を算出する
- これがある閾値 τ より低ければ $(p(x^{\text{NEW}}) < \tau)$ 異常として報告する

多次元データのモデル： 多次元正規分布の最尤推定

- データが多次元の場合は、たとえば多次元正規分布：

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{D/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right)$$


- 正常データ $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \in \mathbb{R}^d$ からパラメータを最尤推定

- 平均： $\hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$

- 分散共分散行列： $\hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \hat{\boldsymbol{\mu}}) (\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top$

再構成誤差を用いた異常検知の考え方： モデルによる再構成誤差が大きいデータを異常と考える

- 符号化 $\mathbf{h} = f(\mathbf{x})$ と復号化 $\hat{\mathbf{x}} = g(\mathbf{h})$



- 符号化器はデータを低次元に射影する
- 復号化器はもとの空間に戻る
- データ $\mathbf{x}$ が正常なデータなら小さな誤差で復号できるはず
 - 例：ユークリッド距離の場合： $e(\mathbf{x}, \hat{\mathbf{x}}) = \|\mathbf{x} - g(f(\mathbf{x}))\|_2^2$

再構成誤差を用いた異常検知の考え方：

再構成誤差は本質的なデータ表現に載るノイズ

- 低次元空間がデータの本質的な形を捉えているとすると、再構成誤差は「ノイズ」として解釈できる


- 大きいノイズを含むものを外れ値とする
- 射影の距離が再構成誤差にあたる

- 再構成誤差 $\| \mathbf{x} - \hat{\mathbf{x}} \|_2^2$ が正規分布：

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{D/2}} \exp \left(-\frac{1}{2} \| \mathbf{x} - \hat{\mathbf{x}} \|_2^2 \right)$$


に従うとして $p(\mathbf{x}^{\text{NEW}}) < \tau$ で判定すると
前述の枠組みで解釈できる

2次元データを1次元に射影した例




ニューラルネットによる符号化・復号化： 自己符号化器（オートエンコーダ）

- 符号化器 $\mathbf{h} = f(\mathbf{x})$ と復号化器 $\hat{\mathbf{x}} = g(\mathbf{h})$ をどう実現するか
- 主成分分析（PCA）：符号化 $\mathbf{h} = \mathbf{F}\mathbf{x}$ ・ 復号化 $\hat{\mathbf{x}} = \mathbf{G}\mathbf{h}$ とした場合（ $\mathbf{F}$ と $\mathbf{G}$ は行列、つまり線形変換）
- 自己符号化器は符号化・復号化をニューラルネットでおこなうもの



自己符号化器による異常検知： 自己符号化器の再構成誤差を異常度とする

- 符号化 $\mathbf{h} = f(\mathbf{x})$ と復号化 $\hat{\mathbf{x}} = g(\mathbf{h})$



- 正常なデータから符号化器・復号化器を推定：

$$(f, g) = \operatorname{argmin}_{f, g} \sum_i \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2$$

- 新たなデータ $\mathbf{x}^{\text{NEW}}$ の再構成誤差を異常度とする：

$$\|\mathbf{x}^{\text{NEW}} - \hat{\mathbf{x}}^{\text{NEW}}\|_2^2$$

まとめ： 異常検知

- 異常検知：システムの障害は一旦起こると大損失であり早期検出したい
- 異常データは稀なので、正常時をモデル化する
 - 多次元正規分布、ニューラルネットワーク（オートエンコーダ）
- データの「珍しさ」によって異常度を判定
 - 確率モデルからの生起確率によってデータの異常度を判定
 - 再構成誤差の大きさによってデータの異常度を判定

まとめ

統計的モデリングの考え方：

データから母集団を知る

- 部分（データ）から全体（母集団＝データの生成機構）を知る
- 推定されたモデルのさまざまな使い方
 - 予測（将来のデータについて）
 - モデルそのものから知識を得る
 - ◆ 回帰モデルにおける説明変数と結果変数の関連
 - ◆ 適切な仮定や研究デザインに基づく因果推論
 - データの検証
 - ◆ 異常発見
 - データの生成：近年盛ん

その他のトピック：

本講義で紹介できなかった（が重要な）トピック

- 潜在変数モデル：決して観測されない変数
 - トピックモデル、主成分分析・因子分析
 - EMアルゴリズムによる推定
- 独立でない構造をもったデータのモデリング：
時系列、ネットワーク構造
- 計算統計（おもにベイズモデリングの実施のための技）
 - マルコフ連鎖モンテカルロ・変分推論
- 応用：推薦システム、機械学習

アンケートの実施：

Kulasisからアンケートを実施してください

- アンケートを実施してください：
統計的モデリング基礎（鹿島久嗣）を選択
- スマートフォン、ノート又はタブレット型パソコンで実施
 - 持っていない方は、授業後、サテライト演習室や自宅のパソコンからアンケートに答えてください
- このアンケートは、授業について受講者の皆さんからの意見を聴き授業・教育環境の改善に役立てようとするためのものです。
- アンケートは無記名方式であり、回答内容が成績評価に影響することはありません